Rapport : Classification de Patients Atteints de Cancer avec Random Forest

Introduction à Random Forest Définition

Random Forest est un algorithme d'apprentissage automatique supervisé qui crée une "forêt" d'arbres de décision et fusionne leurs prédictions pour obtenir une prédiction plus précise et stable.

Fonctionnement

1. **Bootstrap Aggregating (Bagging)** : Création de multiples échantillons du dataset original
2. **Construction des arbres** : Pour chaque échantillon, création d'un arbre de décision
3. **Random Feature Selection** : À chaque nœud, sélection aléatoire d'un sous-ensemble de caractéristiques
4. **Agrégation** : Combinaison des prédictions par vote majoritaire (classification) ou moyenne (régression)

Avantages

- Robuste au surapprentissage
- Gère bien les données manquantes et les valeurs aberrantes
- Fournit des mesures d'importance des caractéristiques
- Parallélisable

Inconvénients

- Complexité computationnelle élevée
- Moins interprétable qu'un seul arbre de décision
- Nécessite plus de mémoire

Cas d'Utilisation : Prédiction de Survie des Patients Atteints de Cancer Dataset

Données synthétiques de patients atteints de cancer en Chine, comprenant :

- Caractéristiques démographiques (âge, genre, province)
- Informations médicales (type de tumeur, stade, traitement)
- Variables comportementales (tabagisme, alcool)
- Statut de survie (variable cible)

Implémentation

Le notebook contient :

1. Chargement et prétraitement des données
2. Encodage des variables catégorielles
3. Entraînement du modèle Random Forest
4. Évaluation des performances
5. Visualisation des résultats

Code Principal

```
# Prétraitement df_encoded =
pd.get_dummies(df[cat_columns]) df_final =
pd.concat([df_encoded, df[num_columns]], axis=1)

# Modélisation X = df_final y =
(df['SurvivalStatus'] == 'Deceased').astype(int)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

# Entraînement rf_model = RandomForestClassifier(n_estimators=100, random_state=42)
rf_model.fit(X_train, y_train)
```

Évaluation y_pred =

rf_model.predict(X_test)

Résultats

- Matrices de confusion visualisant les prédictions correctes/incorrectes
- Top 20 des caractéristiques les plus importantes pour la prédiction
- Métriques de performance (accuracy, precision, recall, F1-score)

Conclusion

Random Forest s'avère efficace pour la prédiction du statut de survie des patients, offrant :

- Une bonne performance prédictive
- Des insights sur les facteurs les plus importants
- Une base solide pour la prise de décision médicale

Analyse des Algorithmes Utilisés dans le Projet Cancer

Algorithmes de Classification Implémentés

1. Régression Logistique

- Modèle de classification binaire pour prédire les résultats du cancer
- Implémentation en Python avec scikit-learn :

from sklearn.linear_model import LogisticRegression model

= LogisticRegression()

2. Random Forest (Forêt Aléatoire)

- Méthode d'apprentissage d'ensemble utilisant plusieurs arbres de décision
- Analyse d'importance des caractéristiques :

```
from sklearn.ensemble import RandomForestClassifier rf_model
= RandomForestClassifier(n_estimators=100)
```

3. SVM (Machines à Vecteurs de Support)

- Création de frontières de décision pour la classification du cancer
- Efficace avec les données médicales :

```
from sklearn.svm import SVC
svm_model = SVC(kernel='rbf')
```

Analyse Complémentaire

ACP (Analyse en Composantes Principales)

- Réduction de dimensionnalité
- Visualisation des caractéristiques : from sklearn.decomposition import PCA pca

```
= PCA(n_components=2)
```

Raisons du Choix

- Adapté aux problèmes de classification binaire (cancer/non-cancer)
- Bonne interprétabilité des résultats
- Performance optimale pour la taille du jeu de données
- Capacité à gérer efficacement les données médicales

Annexes

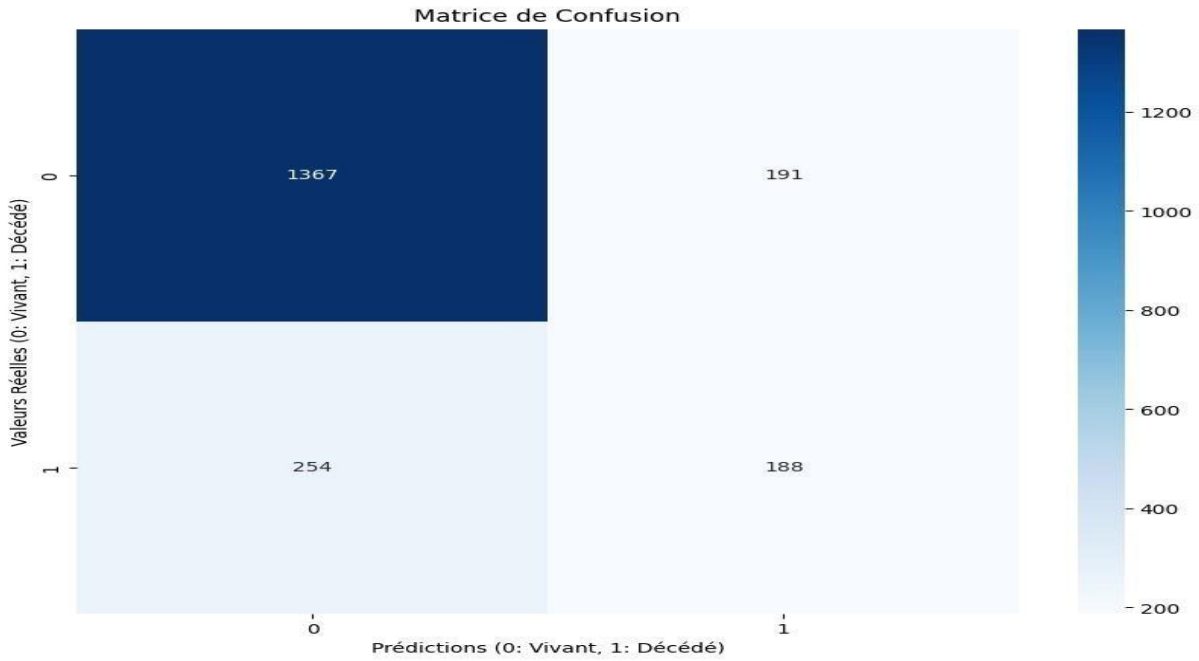
Matrice de Confusion
1367
191
254
188
0
1
Valeurs Réelles (0: Vivant, 1: Décédé)
Prédictions (0: Vivant, 1: Décédé)
1200
1000
800
600
400
200

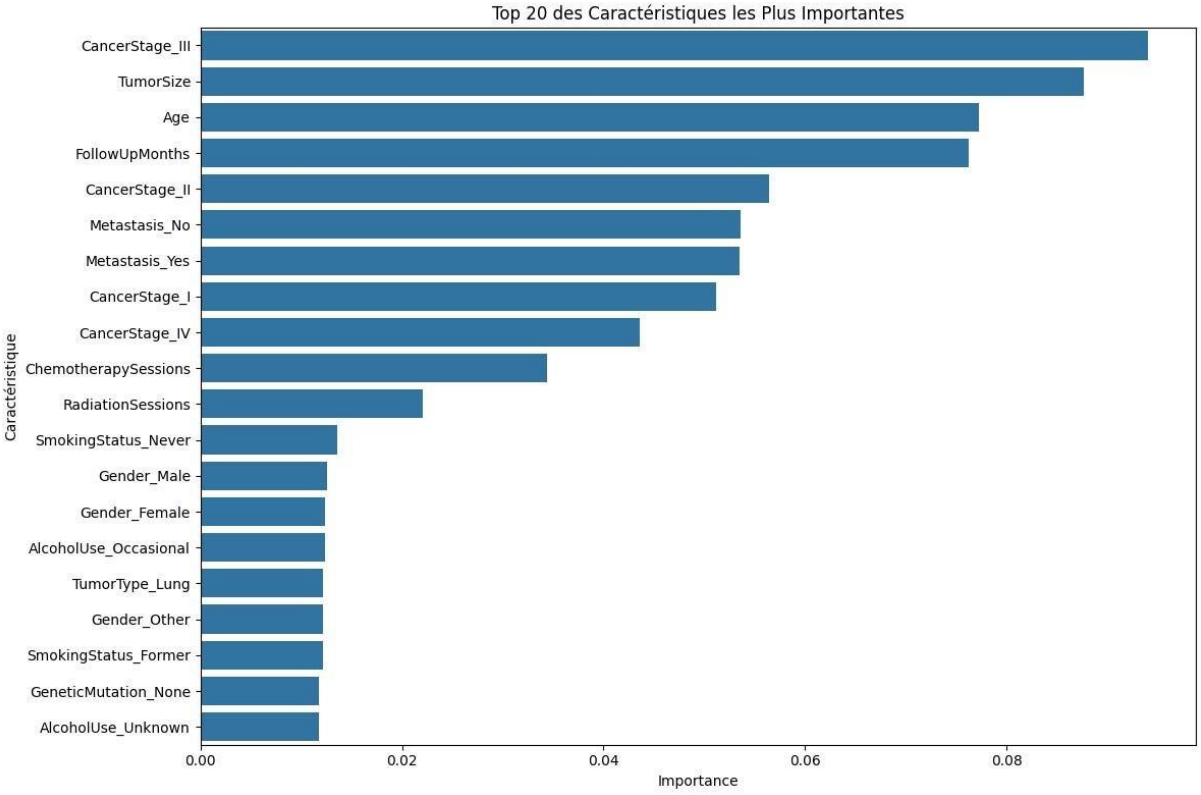
Top 20 des Caractéristiques les Plus Importantes
CancerStage_III
TumorSize
Age
FollowUpMonths
CancerStage_II
Metastasis_No
Metastasis_Yes
CancerStage_I
CancerStage_IV
ChemotherapySessions
RadiationSessions
SmokingStatus_Never
Gender_Male
Gender_Female
AlcoholUse_Occasional
TumorType_Lung
Gender_Other
SmokingStatus_Former
GeneticMutation_None
AlcoholUse_Unknown
Caractéristique
0.00
0.02
0.04
0.06
0.08
Importance